



TẬP ĐOÀN CÔNG NGHIỆP - VIỄN THÔNG QUÂN ĐỘI

BÁO CÁO MINI-PROJECT

G-SQM:

**AUTOMATED GEOGRAPHY-SPECIFIC
SIGNAL QUALITY MONITORING**

Mai Thành Duy

maithanhduy1705@gmail.com

Chương trình Viettel Digital Talent 2026

Lĩnh vực: Data Engineering

Mentor: Dương Nguyễn Việt Anh

Đơn vị: Tổng công ty Mạng lưới Viettel

HÀ NỘI - 2026

Tóm tắt

Trong việc giám sát và phân tích dữ liệu vùng phủ sóng của các nhà mạng viễn thông, MDT (*Minimization of Drive Tests*) là cơ chế cốt lõi cho phép thu thập tự động dữ liệu chất lượng tín hiệu ẩn danh từ thiết bị người dùng. Tại Tổng công ty mạng lưới Viettel đã xây dựng thành công hệ thống **ZDT** (Zero Driving Tests) để tự động thu thập dữ liệu log MDT **đơn lẻ** theo vị trí người dùng. Mặc dù giúp tiết kiệm đáng kể chi phí so với phương pháp đo kiểm thực địa truyền thống, quy trình xử lý khối lượng log MDT khổng lồ hiện nay vẫn chưa có luồng phân tích nào tự động thay thế cho những tác vụ thủ công. Đặc biệt, việc đánh giá chất lượng sóng theo từng điểm đơn lẻ hay đánh giá dựa trên mức trung bình của toàn trạm phát còn thiếu toàn diện, không cung cấp một cái nhìn chi tiết, gây khó khăn cho việc nhận diện chính xác trải nghiệm thực tế của người dùng.

Để giải quyết bài toán này, đề tài đề xuất và xây dựng hệ thống **G-SQM** (*Automated Geography-Specific Signal Quality Monitoring*) – hệ thống giám sát tự động chất lượng vùng phủ tín hiệu chuyên biệt tới từng phân vùng địa lý đầu tiên. Hệ thống áp dụng kiến trúc *Data Lakehouse* cùng các công cụ dữ liệu lớn như Apache Airflow và Apache Spark để xây dựng luồng xử lý dữ liệu tự động (End-to-End Pipeline). Điểm nhấn kỹ thuật của G-SQM là việc ứng dụng thuật toán mã hóa không gian **H3** để chuẩn hóa hàng triệu điểm đo rời rạc thành các phân vùng lục giác đồng nhất, giúp phát hiện chính xác các điểm chất lượng sóng theo phân vùng mà bị che lấp bởi cách đánh giá đơn lẻ hay trạm phát.

Bên cạnh bài toán giám sát, hệ thống còn tích hợp mô hình học máy **Prophet** để dự báo biến động của mật độ người dùng (*User Density*) và cường độ tín hiệu (*RSRP*) trước 24 giờ. Kết hợp với các truy vấn SQL (*Rule-based*) trên Trino, hệ thống cung cấp cơ chế cảnh báo sớm, chủ động cảnh báo các phân vùng không gian có bất thường.

Kết quả thực nghiệm cho thấy G-SQM mang lại giá trị thực tiễn về cả mặt vận hành và kinh tế. Hệ thống giúp tự động hóa > 80% các bước vận hành toàn trình, cung cấp Dashboard trực quan thay thế cho các thao tác trích xuất thủ công của kỹ sư. Đồng thời,

hệ thống hỗ trợ đưa ra quyết định tối ưu tài nguyên thông qua việc đề xuất các trạm vào trạng thái nghỉ , cũng như tối ưu vùng phủ sóng kịp thời để giảm tỷ lệ khách hàng rời mạng (*Churn Rate*).

Từ khóa: *G-SQM, Tự động hóa giám sát, MDT, Data Lakehouse, Apache Spark, Spatial Hashing, Prophet, cảnh báo sớm, tối ưu chất lượng sóng vô tuyến.*

Lời cảm ơn

Em xin gửi lời cảm ơn chân thành và sâu sắc nhất tới người đã hướng dẫn và đồng hành cùng em trong dự án, anh **Đương Nguyễn Việt Anh**, kỹ sư Dữ liệu lớn, Trung tâm Nền tảng Công nghệ và Chuyển đổi số, Tổng công ty Mạng lưới Viettel. Trong suốt thời gian thực hiện dự án, sự hỗ trợ và động viên của anh không chỉ thúc đẩy và giúp đỡ em về mặt chuyên môn mà còn định hướng cho sự phát triển của em trên con đường theo đuổi sự nghiệp sau này.

Đồng thời, em cũng xin gửi lời cảm ơn tới tất cả giảng viên đào tạo lĩnh vực **Data Engineering** tại chương trình **Viettel Digital Talent 2026**. Kiến thức và những chia sẻ từ các anh chị đã và sẽ giúp đỡ chúng em rất nhiều trong quá trình học tập, làm việc và phát triển trong tương lai. Bên cạnh đó, em cũng xin gửi lời cảm ơn tới tất cả các bạn thực tập sinh trong lĩnh vực Data Engineering nói riêng và toàn chương trình nói chung vì đã giúp đỡ và đồng hành cùng nhau trong quá trình học tập tại chương trình năm nay.

Cuối cùng, em xin cảm ơn **Tập đoàn Công nghiệp - Viễn thông Quân đội Viettel** vì đã cho em cơ hội tham gia và học tập tại chương trình VDT 2026, một hành trình với không chỉ kiến thức mà còn là những kinh nghiệm và cơ hội mới, là hành trang cho hành trình theo đuổi tương lai.

Lời cam đoan

Tôi, Mai Thành Duy, sinh viên Đại học Bách Khoa Hà Nội, thực tập sinh lĩnh vực đào tạo Data Engineering, chương trình Viettel Digital Talent 2026, xin cam đoan dự án với đề tài “G-SQM : Automated Geography-Specific Signal Quality Monitoring (Giám sát tự động chất lượng vùng phủ tín hiệu chuyên biệt tối từng phân vùng địa lý)” là sản phẩm nghiên cứu gốc của tôi. Tôi xin cam đoan toàn bộ nội dung trình bày trong báo cáo hoàn toàn không sao chép từ bất kỳ tài liệu nào khác. Ngoài ra, tôi cũng không sử dụng bất kỳ một phát biểu, kết quả hay công trình nghiên cứu của người khác mà không trích dẫn đầy đủ. Tôi xin cam mã nguồn của dự án này là do tôi tự phát triển, không sao chép mã nguồn của người khác. Tôi xin chịu hoàn toàn trách nhiệm theo quy định đối với các cam kết của mình.

Thực tập sinh

Mai Thành Duy

Mục lục

Tóm tắt	iii
Lời cảm ơn	v
Lời cam đoan	vi
Mục lục	vii
Thuật ngữ và viết tắt	ix
Danh mục hình ảnh	x
1 Giới thiệu chung	1
1.1 Đặt vấn đề	1
1.2 Phát biểu bài toán	3
1.3 Đóng góp của dự án	4
1.4 Cấu trúc báo cáo	4
2 Kiến thức nền tảng	6
2.1 Giao thức truyền tải tệp tin bảo mật SFTP	6
2.2 Công cụ điều phối luồng công việc Apache Airflow	6
2.3 Hệ thống tính toán phân tán Apache Spark	7
2.4 Công cụ kiểm định chất lượng dữ liệu Great Expectations	7
2.5 Kiến trúc lưu trữ Data Lakehouse	7
2.5.1 MinIO (Object Storage)	8
2.5.2 Delta Lake	8
2.5.3 Hive Metastore (Metadata Catalog)	8
2.6 Thuật toán phân vùng không gian Uber H3	8
2.7 Mô hình dự báo Prophet	9
2.8 Công cụ truy vấn phân tán Trino	9
2.9 Ứng dụng Web và Trực quan hóa dữ liệu	10

2.9.1	Khung phát triển ứng dụng Web Streamlit	10
2.9.2	Thư viện phân tích không gian Kepler.gl	10
2.9.3	Thư viện trực quan hóa chuyên sâu Chart.js	10
3	Kiến trúc hệ thống G-SQM	12
3.1	Kiến trúc tổng quan	12
3.2	Module 1: Thu thập dữ liệu (Data Ingestion)	14
3.3	Module 2: Kiểm soát chất lượng dữ liệu (Data Quality Check)	16
3.4	Module 3: Nội suy không gian (Spatial Modeling)	17
3.5	Module 4: Thiết kế mô hình dữ liệu (Gold Layer)	19
3.6	Module 5: Dự báo và cảnh báo sớm (Forecasting & Warning)	21
3.6.1	Mô hình dự báo chuỗi thời gian Prophet	21
3.6.2	Huấn luyện phân tán và tối ưu hóa tài nguyên	22
3.6.3	Cơ chế cảnh báo sớm tự động	23
3.7	Hệ thống điều phối luồng công việc (Airflow Pipelines)	23
4	Thực nghiệm	25
4.1	Phân tích tập dữ liệu thực nghiệm	25
4.2	Môi trường và cấu hình thực nghiệm	26
4.3	Kết quả thực nghiệm	27
4.3.1	Kết quả thực nghiệm module thu thập dữ liệu	27
4.3.2	Kết quả thực nghiệm module kiểm soát chất lượng (Data Quality Check)	28
4.3.3	Kết quả thực nghiệm module thiết kế mô hình dữ liệu (Data Modeling)	31
4.3.4	Kết quả thực nghiệm module cảnh báo	32
4.3.5	Kết quả thực nghiệm module dự báo & cảnh báo sớm	34
4.4	Dashboard trực quan hóa dữ liệu (Command Center)	38
	Kết luận	45
	Tài liệu tham khảo	46

Thuật ngữ và viết tắt

G-SQM	Geography-Specific Signal Quality Monitoring - Luồng giám sát tự động chất lượng vùng phủ tín hiệu chuyên biệt tối từng phân vùng địa lý
MAE	Mean Absolute Error, sai số tuyệt đối trung bình
MDT	Minimisation of Drive Test
RMSE	Root Mean Square Error, sai số bình phương trung bình
ZDT	Zero Driving Test

Danh sách hình vẽ

1.1	Mình họa việc xe đi đo kiểm chất lượng tín hiệu	2
1.2	Phân bố các điểm đo log MDT trong không gian	2
3.1	Kiến trúc luồng xử lý phân tích dữ liệu toàn trình G-SQM.	13
3.2	Module thu thập dữ liệu	14
3.3	Module Data Quality Check	16
3.4	Ví dụ về phân vùng địa lý H3	18
3.5	Module Data Modeling	19
3.6	Mô hình dữ liệu Star Schema tại tầng Gold.	20
3.7	Module Dự báo và cảnh báo	21
3.8	DAGs	24
4.1	Kết quả thực nghiệm module thu thập dữ liệu qua MinIO storage	27
4.2	Cấu trúc phân loại dữ liệu tại tầng Silver trên hệ thống MinIO.	28
4.3	Dữ liệu sạch (mdt_clean) được lưu trữ dưới định dạng Delta Lake và phân vùng theo ngày.	29
4.4	Thời gian thực thi tác vụ kiểm soát chất lượng (2_run_quality_check) trên Apache Airflow.	29
4.5	Dữ liệu bảng Fact (fact_mdt_hourly) được lưu trữ chuẩn hóa tại tầng Gold trên MinIO.	31
4.6	Thời gian thực thi tác vụ xây dựng mô hình dữ liệu (3_build_fact_model) trên Apache Airflow.	31
4.7	Giao diện cảnh báo vùng lốm sọc tối liên tục (màu đỏ) trên Dashboard.	33
4.8	Bản đồ không gian tự động highlight các phân vùng H3 lốm sọc trong vòng 3 tiếng liên tục.	34
4.9	Email tự động cảnh báo các bất thường	34
4.10	Giao diện cảnh báo sớm các vùng tối (màu vàng) trên Dashboard.	35
4.11	Biểu đồ chuỗi thời gian hiển thị dự báo biến động trong 24H.	36
4.12	Biểu đồ phân phối thời gian thực thi (Task Duration) chi tiết của tác vụ chạy mô hình Prophet trên Apache Airflow.	38

4.13	Giao diện Dashboard trực quan hóa dữ liệu vùng phủ G-SQM.	39
4.14	Giao diện Dashboard trực quan hóa dữ liệu vùng phủ G-SQM.	39
4.15	Chất lượng tín hiệu từng phân vùng.	40
4.16	Bản đồ	41
4.17	So sánh tuần này và tuần trước	42
4.18	Cửa sổ phân tích	43

Chương 1

Giới thiệu chung


Chương này cung cấp cái nhìn tổng quan về nghiên cứu, bao gồm bối cảnh, động lực thúc đẩy, mục tiêu cụ thể, cùng các đóng góp chính của dự án **G-SQM (Geography-Specific Signal Quality Monitoring)** trong việc giải quyết bài toán giám sát chất lượng vùng phủ tín hiệu sóng vô tuyến.

1.1 Đặt vấn đề

Để đánh giá chất lượng sóng vô tuyến của các nhà mạng viễn thông, cơ chế thu thập MDT (*Minimization of Drive Tests*) hiện đang được ứng dụng rộng rãi nhằm thu thập dữ liệu chất lượng tín hiệu ẩn danh từ thiết bị của người dùng **trong quá trình họ di chuyển** theo chuẩn 3GPP[1]. Mục đích cốt lõi của giải pháp này là thay thế phương pháp đo kiểm truyền thống tốn kém, vốn đòi hỏi phải cử kỹ sư chuyên trách lái xe đi đo sóng thực địa.



Hình 1.1: Minh họa việc xe đi đo kiểm chất lượng tín hiệu



Hình 1.2: Phân bố các điểm đo log MDT trong không gian

Thực tế tại Viettel Network, đơn vị đã xây dựng thành công hệ thống **ZDT** (Zero Driving Tests) để tự động thu thập dữ liệu log MDT **đơn lẻ** theo vị trí người dùng. Tuy nhiên, quy trình vận hành hiện tại vẫn đang phải đối mặt với thách thức lớn về xử lý dữ liệu. Khối lượng log dữ liệu thô khổng lồ sinh ra hàng giờ hiện vẫn tồn tại ở dạng tệp rời rạc, chưa có luồng xử lý và tổng hợp tự động hóa dẫn đến việc thiếu đi góc nhìn trực

quan theo thời gian thực để đánh giá toàn cục mạng lưới.

Giám sát chất lượng mạng lưới hiện nay đang phải đối mặt với thách thức lớn về khả năng vận hành. Mặc dù ZDT giúp thu thập tự động dữ liệu vùng phủ sóng, nhưng khối lượng log dữ liệu thô khổng lồ sinh ra hàng giờ hiện vẫn tồn tại ở dạng tệp rời rạc, chưa có luồng xử lý tự động hóa. Đội ngũ kỹ sư phải vận hành thủ công, dẫn đến việc thiếu đi góc nhìn trực quan theo thời gian thực để đánh giá toàn cục mạng lưới. Hơn nữa, việc đánh giá chất lượng sóng dựa trên các điểm đo từ thiết bị người dùng đơn lẻ hoặc có thể dựa trên mức trung bình của trạm phát dễ làm mờ đi các điểm chất lượng sóng yếu cục bộ. Thực tế cho thấy một trạm có chỉ số tổng thể rất tốt nhưng một tuyến phố cụ thể bên trong vẫn có thể bị mất sóng hoàn toàn.

Do đó, việc xây dựng một tiến trình tự động thu thập, gom nhóm và phân tích chất lượng sóng chuyên biệt tới từng phân vùng địa lý cụ thể là yêu cầu cấp thiết. Hướng tiếp cận này kết hợp với mô hình dự đoán sẽ hỗ trợ giám sát trực quan và cảnh báo sớm tình trạng mạng lưới, qua đó giúp tiết kiệm nhân lực, nhận diện chính xác các điểm mù cũng như vùng lãng phí tài nguyên giúp tác vụ tối ưu của các kỹ sư sóng vô tuyến dễ dàng hơn.

1.2 Phát biểu bài toán

Mục tiêu của đề tài này là Xây dựng hệ thống G-SQM (Geography-Specific Signal Quality Monitoring) nhằm tự động giám sát và dự báo chất lượng tín hiệu chuyên biệt tới từng phân vùng không gian -cụ thể ở đây là lưới lục giác H3.

1. Bài toán tự động giám sát (Automated Monitoring):

- **Đầu vào:** Tập dữ liệu vùng phủ sóng MDT và thông tin cấu hình trạm phát.
- **Đầu ra:** Xác định chính xác trạng thái của từng ô lưới H3 thông qua việc phân tích tương quan giữa **Chất lượng tín hiệu** và **Mật độ người dùng** (nhằm phát hiện phân vùng bất thường).

2. Bài toán Dự báo và Cảnh báo sớm (Early Warning):

- **Đầu vào:** Chuỗi thời gian lịch sử về chất lượng tín hiệu và mật độ người dùng tại các ô H3.
- **Đầu ra:** Dự báo biến động trong 24 giờ tiếp theo để đưa ra danh sách các phân vùng H3 cần sự can thiệp tối ưu của các kỹ sư.

1.3 Đóng góp của dự án

Đề tài đóng góp những giải pháp thực tiễn thông qua các thành phần cốt lõi:

- **Xây dựng luồng dữ liệu phân tích tự động (End-to-End Pipeline):**
 - Thiết kế và triển khai hoàn chỉnh luồng xử lý dữ liệu log MDT thô.
 - Cung cấp hệ thống Dashboard giám sát trực quan, giảm thiểu triệť để các thao tác trích xuất và tổng hợp dữ liệu thủ công của kỹ sư.
- **Đề xuất phương pháp giám sát theo phân vùng lưới (Spatial Hashing):**
 - Ứng dụng hệ thống lưới lục giác H3 để chuẩn hóa các tọa độ điểm đo rời rạc thành các phân vùng địa lý đồng nhất.
 - Nhận diện chính xác các phân vùng địa lý bất thường (ví dụ: điểm lổm sóng - Coverage Hole).
- **Tích hợp cảnh báo sớm (Early Warning):**
 - Triển khai mô hình dự báo biến động chất lượng tín hiệu trước 24 giờ.
 - Hỗ trợ stakeholders chủ động đưa ra các quyết định tối ưu.
- **Giá trị thực tiễn đem lại:**
 - **Tối ưu tài nguyên:** Ước tính tiết kiệm hàng tỷ VNĐ/năm trên quy mô mạng lưới thông qua việc tự động phát hiện mật độ người dùng thấp và lên lịch cho trạm nghỉ.
 - **Tối ưu vùng phủ & Vận hành:** Tự động hóa > 80% các bước vận hành toàn trình ; phát hiện và tối ưu kịp thời các vùng lổm sóng, qua đó giúp giảm tỷ lệ khách hàng rời mạng (Churn Rate).

1.4 Cấu trúc báo cáo

Báo cáo được trình bày theo cấu trúc logic bao gồm bốn chương chính và phần kết luận:

Chương 1: Giới thiệu chung. Giới thiệu tổng quan về bối cảnh, động lực nghiên cứu và các đóng góp chính.

Chương 2: Kiến thức nền tảng. Trình bày kiến thức nền tảng về công nghệ xử lý dữ liệu lớn, kiến trúc Lakehouse và các phương pháp mô hình hóa dữ liệu địa lý.

Chương 3: Kiến trúc hệ thống G-SQM. Mô tả chi tiết kiến trúc hệ thống G-SQM, thiết kế của từng phân hệ (Ingestion, Processing, Serving) và vai trò của từng thành phần.

Chương 4: Thực nghiệm. Trình bày quá trình thực nghiệm, kết quả đánh giá mô hình và hiệu quả của hệ thống thông qua các demo trực quan trên dashboard.

Kết luận. Tổng kết lại những kết quả đạt được, đồng thời đưa ra các hạn chế hiện tại và định hướng phát triển hệ thống trong tương lai.

Chương 2

Kiến thức nền tảng

2.1 Giao thức truyền tải tệp tin bảo mật SFTP

SFTP (*Secure File Transfer Protocol*) là một giao thức mạng cung cấp khả năng truyền tải và quản lý tệp tin một cách an toàn thông qua một luồng dữ liệu bảo mật, thường dựa trên giao thức SSH (*Secure Shell*). Trong bối cảnh hạ tầng viễn thông, tính bảo mật và tính toàn vẹn của dữ liệu log là yếu tố cực kỳ quan trọng, đòi hỏi dữ liệu không bị can thiệp trong quá trình truyền dẫn.

Đối với hệ thống G-SQM, máy chủ SFTP đóng vai trò là điểm chạm đầu tiên (Data Source). Các tệp log MDT thô được hệ thống mạng lõi của nhà mạng định kỳ đóng gói và đẩy về máy chủ SFTP này. Từ đây, luồng công việc của Apache Airflow sẽ tự động kết nối, xác thực và trích xuất (*fetch*) các tệp dữ liệu về vùng lưu trữ đối tượng MinIO để bắt đầu chu trình phân tích mà không làm rò rỉ dữ liệu nhạy cảm ra bên ngoài mạng lưới.

2.2 Công cụ điều phối luồng công việc Apache Airflow

Trong kiến trúc hệ thống G-SQM, Apache Airflow đóng vai trò điều phối (Orchestrator) toàn bộ chu trình xử lý dữ liệu tự động theo chu kỳ hàng giờ (*Hourly Batch processing*). Đây là một nền tảng mã nguồn mở chuyên dụng để lập lịch và giám sát các luồng công việc quy mô lớn thông qua đồ thị có hướng không chu trình DAG (*Directed Acyclic Graph*) viết bằng Python[2].

Nhờ cơ chế tự động chạy lại khi gặp sự cố (*Auto-Retry*), Airflow đảm bảo tính toàn vẹn và độ sẵn sàng cao cho toàn bộ luồng dữ liệu từ nguồn đến đích.

2.3 Hệ thống tính toán phân tán Apache Spark

Đóng vai trò là động cơ xử lý lõi (Compute Engine) trong hệ thống, Apache Spark chịu trách nhiệm thực thi toàn bộ các tác vụ tính toán nặng nề được Airflow kích hoạt. Spark xử lý dữ liệu phân tán tốc độ cao dựa trên cơ chế tính toán trong bộ nhớ (*In-Memory Computing*), giải quyết triệt để nút thắt cổ chai về hiệu năng của các mô hình truyền thống.

Đối với G-SQM, lượng log MDT đổ về hàng giờ là cực kỳ lớn. Spark đảm nhiệm việc đọc dữ liệu từ MinIO, làm sạch, chuẩn hóa, và đặc biệt là thực hiện các phép toán kết hợp không gian (*Spatial Join*) phức tạp để gán tọa độ điểm đo vào các ô lưới lục giác H3. Khả năng tối ưu hóa của Spark kết hợp với định dạng Delta Lake cho phép hệ thống ghi đè dữ liệu có điều kiện một cách an toàn và song song trên toàn bộ cụm máy chủ (Cluster)[10].

2.4 Công cụ kiểm định chất lượng dữ liệu Great Expectations

Trong các hệ thống dữ liệu quy mô lớn, chất lượng của dữ liệu đầu vào quyết định trực tiếp đến độ tin cậy của các mô hình dự báo đầu ra theo nguyên lý "Garbage In, Garbage Out". **Great Expectations (GX)** là một thư viện mã nguồn mở bằng ngôn ngữ Python hàng đầu chuyên dụng để định nghĩa, kiểm định và văn bản hóa (*document*) chất lượng dữ liệu tự động [5].

Trong chu trình đường ống dữ liệu của G-SQM, thay vì viết các đoạn mã kiểm tra tính hợp lệ thủ công, hệ thống sử dụng GX để thiết lập các "kỳ vọng" (*Expectations*) – tức là các quy tắc kinh doanh chuẩn. Ví dụ: tham số Cell ID không được để trống, tọa độ GPS (Lat/Lon) phải nằm trong giới hạn lãnh thổ Việt Nam, hoặc cường độ sóng RSRP phải nằm trong ngưỡng hợp lý (từ -140 dBm đến -40 dBm). Tại bước *2_run_quality_check*, GX sẽ quét qua toàn bộ dữ liệu tại tầng Bronze, sinh ra báo cáo chất lượng (*Data Quality Audit*) và tự động cô lập các bản ghi vi phạm. Điều này đảm bảo dữ liệu đưa lên tầng Silver và Gold để huấn luyện mô hình luôn sạch và chính xác tuyệt đối.

2.5 Kiến trúc lưu trữ Data Lakehouse

Hệ thống áp dụng kiến trúc **Data Lakehouse** – kết hợp sự linh hoạt của *Data Lake* với tính toàn vẹn của *Data Warehouse* – để lưu trữ và quản lý luồng dữ liệu qua các tầng Bronze, Silver và Gold.

2.5.1 MinIO (Object Storage)

MinIO là hệ thống lưu trữ đối tượng (*Object Storage*) tương thích với chuẩn S3, đóng vai trò là hạ tầng lưu trữ vật lý cho toàn bộ hệ thống Lakehouse. MinIO cho phép lưu trữ các tệp tin log MDT thô ngay khi được kéo về từ SFTP với quy mô lớn, tính sẵn sàng cao và khả năng mở rộng không giới hạn, tạo nền tảng vững chắc để Apache Spark phân tác tính toán.

2.5.2 Delta Lake

Nằm trên hạ tầng vật lý của MinIO là Delta Lake – lớp lưu trữ (*Storage Layer*) chịu trách nhiệm quản lý cấu trúc dữ liệu[3]. Delta Lake cung cấp cơ chế *ACID Transaction*, đảm bảo tính nhất quán của dữ liệu khi Spark thực hiện ghi/đọc đồng thời. Nó ngăn chặn các bản ghi lỗi làm hỏng hệ thống và cho phép truy vấn lại dữ liệu quá khứ (*Time Travel*), tạo nên sự tin cậy tuyệt đối cho các tầng Silver và Gold.

2.5.3 Hive Metastore (Metadata Catalog)

Để các công cụ xử lý (Apache Spark) và công cụ truy vấn (Trino) có thể hiểu được cấu trúc bảng (*Schema*) và vị trí vật lý của dữ liệu đang nằm ở đâu trong MinIO, hệ thống cần một danh mục siêu dữ liệu tập trung. Trong kiến trúc Lakehouse, **Hive Metastore** đảm nhiệm vai trò trung tâm lưu trữ siêu dữ liệu (*Metadata Catalog*) này.

Mỗi khi Apache Spark ghi một bảng Delta mới hoặc thêm một phân vùng (*Partition*) dữ liệu theo giờ vào hệ thống lưu trữ MinIO, thông tin về lược đồ dữ liệu, định dạng file, và đường dẫn thư mục sẽ được tự động đồng bộ đăng ký với Hive Metastore. Nhờ có "cuốn danh bạ" này, khi người dùng thực hiện truy vấn từ Dashboard, engine Trino chỉ cần gọi đến Hive Metastore để lấy siêu dữ liệu là có thể dịch ngay các câu lệnh SQL thành các tác vụ đọc file song song trên MinIO một cách chính xác, đảm bảo sự liên thông dữ liệu mượt mà giữa các thành phần độc lập trong hệ thống.

2.6 Thuật toán phân vùng không gian Uber H3

Tại tầng xử lý nghiệp vụ, thay vì dùng ranh giới hành chính truyền thống, hệ thống sử dụng thuật toán **Uber H3** – hệ thống phân chia lưới không gian dựa trên các lục giác (*hexagons*)[9].

Việc tích hợp H3 vào đường ống dữ liệu Spark mang lại ưu điểm vượt trội:

- **Độ phân giải linh hoạt:** Cho phép chuyển đổi giữa các cấp độ chi tiết dễ dàng (từ cấp thành phố đến tuyến phố).
- **Tính toán hiệu quả:** Các ô lục giác có diện tích đồng nhất giúp phép toán không gian (*neighbor lookup*) tối ưu hơn lưới vuông.
- **Làm mịn dữ liệu:** Giúp gom nhóm các điểm đo MDT rời rạc, loại bỏ nhiễu cục bộ để tạo ra các bản đồ nhiệt (*Heatmap*) và phản ánh chính xác các điểm mù vùng phủ sóng.

2.7 Mô hình dự báo Prophet

Sau khi dữ liệu đã được tổng hợp ở tầng Gold, mô hình **Prophet** (do Meta phát triển) được ứng dụng để phân tích và dự báo chuỗi thời gian[6]. Mô hình dựa trên phương pháp phân tích cộng gộp, biểu diễn qua phương trình toán học tổng quát:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Trong đó $g(t)$ là xu hướng, $s(t)$ là tính mùa vụ, $h(t)$ là tác động của ngày lễ và ϵ_t là sai số ngẫu nhiên.

Prophet là mô hình lõi để dự báo lưu lượng người dùng (*User Density*) và cường độ tín hiệu (*RSRP*) cho 24 giờ tiếp theo tại từng phân vùng H3. Mô hình này xuất ra các khoảng tin cậy (cận trên và cận dưới), từ đó hệ thống kết hợp với các tập luật SQL để tự động phân loại rủi ro (nguy cơ nghẽn, sụt sóng) hoặc đề xuất trạm vào trạng thái *Sleep Mode*.

2.8 Công cụ truy vấn phân tán Trino

Để kết nối lớp dữ liệu Gold lưu trữ trên MinIO với ứng dụng giao diện, hệ thống sử dụng **Trino** làm cầu nối truy vấn (Serving Layer). Trino là công cụ truy vấn SQL phân tán hiệu năng cao, cho phép:

- Truy vấn trực tiếp trên các bảng Delta Lake mà không cần chuyển dữ liệu đi nơi khác.
- Xử lý nhanh các phép toán phức tạp (Join, Aggregation) giữa Fact Table và Dimension Table ở quy mô lớn.
- Cung cấp giao diện chuẩn SQL để ứng dụng Dashboard dễ dàng lấy dữ liệu thông qua JDBC/ODBC[7].

2.9 Ứng dụng Web và Trực quan hóa dữ liệu

Tầng cuối cùng của kiến trúc là giao diện người dùng (Frontend), nơi các kỹ sư viễn thông tương tác trực tiếp với tri thức hệ thống tạo ra.

2.9.1 Khung phát triển ứng dụng Web Streamlit

Trong kiến trúc G-SQM, Streamlit không chỉ đóng vai trò là một thư viện xây dựng giao diện người dùng (UI) đơn thuần, mà hoạt động như một nền tảng điều phối trung tâm (Command Center). Phân hệ này chịu trách nhiệm quản lý trạng thái phiên làm việc (Session State), xử lý các tham số truy vấn động (URL Query Parameters) từ người vận hành (như vùng H3, định danh Cell ID, mốc thời gian) và định tuyến các truy vấn phân tích tổng hợp (OLAP) trực tiếp đến engine Trino. Nhờ kiến trúc phản ứng (Reactive Architecture), Streamlit [4] cho phép hệ thống cập nhật tức thời các tham số điều khiển và tái kết xuất (re-render) luồng dữ liệu từ tầng Gold mà không phát sinh độ trễ tải trang, mang lại trải nghiệm giám sát liền mạch và tập trung.

2.9.2 Thư viện phân tích không gian Kepler.gl

Để đáp ứng bài toán trực quan hóa khối lượng dữ liệu không gian khổng lồ, hệ thống tích hợp bộ khung phân tích Kepler.gl (phát triển bởi Uber) nhúng trực tiếp vào giao diện Web[8]. Vượt trội hơn các công cụ bản đồ tĩnh truyền thống, Kepler.gl khai thác tập lệnh WebGL nhằm tận dụng khả năng xử lý đồ họa phần cứng (GPU Acceleration) ngay trên trình duyệt máy khách. Công nghệ này cho phép kết xuất mượt mà hàng triệu đa giác lưới lục giác H3 và các đường cung vật lý (Arc layers) dưới không gian 3 chiều (3D). Đặc biệt, cơ chế xếp chồng đa lớp (Layer Stacking) của Kepler.gl là chìa khóa cốt lõi giúp G-SQM biểu diễn đồng thời biểu đồ nhiệt (Heatmap) phản ánh trạng thái mạng lưới hiện tại, đan xen cùng các lớp dữ liệu cảnh báo sớm rủi ro (Early Warnings) trên cùng một hệ quy chiếu không gian.

2.9.3 Thư viện trực quan hóa chuyên sâu Chart.js

Nhằm cung cấp các góc nhìn phân tích chuyên sâu (Network Insights) mà bản đồ không gian không thể thể hiện, hệ thống nhúng thư viện Chart.js thông qua các thành phần Web tùy biến (Custom Web Components). Thư viện này được tinh chỉnh để xử lý và biểu diễn ma trận tải tuần hoàn (Heatmap Matrix) phức tạp và các biến động chuỗi thời gian liên tục. Đáng chú ý, Chart.js đóng vai trò thiết yếu trong việc minh họa đầu ra của

thuật toán Prophet; nó cung cấp năng lực vẽ các dải băng rủi ro linh động (Upper/Lower Confidence Intervals) phối hợp với các đường dữ liệu thực tế (Actual vs. Forecast). Cấu trúc đồ họa này cung cấp cho kỹ sư viễn thông một công cụ tương tác trực quan để đánh giá nhanh biên độ sai lệch và nguy cơ suy hao tín hiệu mà không cần can thiệp vào các bảng số liệu thô.


Chương 3

Kiến trúc hệ thống G-SQM

Chương 3 trình bày cấu trúc kiến trúc chi tiết và cơ chế vận hành của hệ thống G-SQM (Geography-Specific Signal Quality Monitoring). Bắt đầu từ phần 3.1, tài liệu cung cấp cái nhìn tổng quan về mô hình kiến trúc phân tầng hệ thống. Các phần tiếp theo sẽ đi sâu vào cấu tạo, thuật toán tối ưu và chức năng cốt lõi của từng phân hệ thành phần trong toàn bộ đường ống dẫn dữ liệu (Data Pipeline).

3.1 Kiến trúc tổng quan

Hệ thống G-SQM được thiết kế và triển khai dựa trên nền tảng kiến trúc hiện đại Data Lakehouse tích hợp trên hệ thống lưu trữ đối tượng MinIO S3, kết hợp năng lực tính toán phân tán mạnh mẽ của Apache Spark và công cụ truy vấn phân tích tốc độ cao Trino Engine. Toàn bộ chu trình xử lý dữ liệu từ thu thập thô đến trực quan hóa thời gian thực được tổ chức thành một chuỗi các phân hệ (modules) khép kín, vận hành tự động và kiểm soát nghiêm ngặt bởi hệ thống điều phối Apache Airflow. Mô hình kiến trúc toàn trình được mô tả chi tiết trong hình 3.1.



Hình 3.1: Kiến trúc luồng xử lý phân tích dữ liệu toàn trình G-SQM.

Luồng xử lý dữ liệu được tối ưu hóa sâu giúp rút ngắn tổng thời gian xử lý toàn trình (End-to-End ETL) từ lúc dữ liệu xuất hiện tại nguồn cho tới khi cấu trúc hóa thành công tại tầng phục vụ phân tích. Hệ thống bao gồm 3 phân hệ cốt lõi phối hợp chặt chẽ:

- **Phân hệ thu thập, kiểm định và nội suy không gian:** Đảm nhiệm vai trò tiếp nhận dòng dữ liệu log chất lượng sóng vô tuyến vô danh và cấu hình trạm từ các máy chủ nguồn, thực hiện làm sạch dữ liệu qua bộ lọc chất lượng tự động, bám tọa độ điểm rời rạc sang lưới không gian lục giác theo chuẩn Uber H3 và lưu trữ tối ưu dưới định dạng Delta Lake.
- **Phân hệ dự báo chuỗi thời gian:** Sử dụng mô hình dự báo học máy Prophet triển khai phân tán trên cụm máy chủ Spark, chịu trách nhiệm phân tích dữ liệu lịch sử để tính toán biến động xu hướng của cường độ tín hiệu và mật độ người dùng trong 24 giờ tiếp theo.
- **Phân hệ cảnh báo và hiển thị:** Khai thác sức mạnh truy vấn OLAP của Trino dựa trên hệ thống luật (Rule-based SQL) kết hợp khoảng tin cậy thuật toán để tự động hóa khâu phát hiện bất thường, khoanh vùng lõm sóng, nghẽn mạng và xuất báo cáo trực quan lên Dashboard điều khiển và gửi email tự động tới kỹ sư vận hành.

Về mặt toán học, hệ thống G-SQM hoạt động như một hàm ánh xạ đa biến. Cho một không gian trạng thái đầu vào bao gồm tập hợp dữ liệu log trắc mục vùng phủ sóng vô tuyến thực địa D_{MDT} , tập hợp cấu hình thông số kỹ thuật và vị trí trạm phát sóng


D_{Cell} , cùng tập hợp các tham số cấu hình truy vấn động từ người vận hành hệ thống $P = \{p_1, p_2, \dots, p_n\}$ (bao gồm mốc thời gian phân tích, định danh trạm phát, độ phân giải lưới không gian). Đầu ra của hệ thống là sự kết hợp của ba tập hợp thành phần mang tính định hướng quyết định:

$$f_{G-SQM}(D_{MDT}, D_{Cell}, \{p_1, p_2, \dots, p_n\}) \rightarrow \{O, F, W\} \quad (3.1)$$

Trong đó:

- $O = \{s_1(data_1), s_2(data_2), \dots, s_m(data_m)\}$ là tập hợp các thông tin điểm đo vô tuyến đã được nội suy cấu trúc và gắn nhãn định vị không gian vào phân vùng lục giác H3 thứ i (s_i).
- $F = \{f_1, f_2, \dots, f_m\}$ là tập hợp các phân tích chuỗi thời gian dự báo cho từng phân vùng không gian cụ thể trong chu kỳ 24 giờ tới.
- $W = \{w_1, w_2, \dots, w_m\}$ là tập hợp các nhãn phân loại rủi ro viễn thông (Cảnh báo lữm sóng, nguy cơ nghẽn tải cục bộ hoặc khuyến nghị tối ưu năng lượng) tương ứng với từng phân vùng.

3.2 Module 1: Thu thập dữ liệu (Data Ingestion)



Hình 3.2: Module thu thập dữ liệu

Mục tiêu của module này là thiết lập đường ống nạp dữ liệu tự động, giải quyết bài toán đồng bộ hóa dữ liệu khối lượng lớn từ hệ thống ghi log ẩn danh thực địa ZDT (Zero Driving Tests) thuộc mạng lõi viễn thông về môi trường phân tích Big Data một cách toàn vẹn và liên tục.


• Cơ chế thu thập

- **Batch Ingestion (MDT log):** Apache Airflow thực thi điều phối các tác vụ kéo dữ liệu từ máy chủ SFTP nguồn. Dữ liệu thô được PySpark đọc trực tiếp

thông qua giao thức `s3a://` để đảm bảo hiệu suất truy xuất cao trên môi trường MinIO. Hệ thống tách biệt luồng xử lý MDT (dữ liệu động) để đảm bảo độ trễ thấp nhất cho các tác vụ phân tích thời gian thực.

- **Triggered Dimension (Cell Config):** Dữ liệu cấu hình trạm phát được chuẩn hóa và lưu trữ tại **Bronze** đóng vai trò là "Single Source of Truth". Tại đây, hệ thống áp dụng kỹ thuật **SCD Type 1 (Merge INTO)** để cập nhật trạng thái mới nhất cho các thông số hạ tầng (tọa độ, góc nghiêng/azimuth) lên bảng chiều tại tầng Gold. Cơ chế này đảm bảo dữ liệu chiều luôn ở phiên bản mới nhất, tạo tiền đề cho các phép join hiệu năng cao mà không gây gánh nặng tính toán về lịch sử cấu hình cũ.
- **Chiến lược lưu trữ và tính nhất quán tại Bronze Layer:**
 - **Đối với dữ liệu MDT (Event-based):** Để đảm bảo tính chịu lỗi và khả năng tái chạy luồng (Idempotency), hệ thống áp dụng phương thức ghi đè có điều kiện thông qua toán tử `replaceWhere`. Các bản ghi được phân vùng nghiêm ngặt theo khóa thời gian (`batch_date`, `batch_hour`), giúp tránh trùng lặp dữ liệu (data duplication) khi luồng công việc gặp sự cố mạng hoặc lỗi hệ thống nguồn.
 - **Đối với dữ liệu Trạm (Dimension-based):** Lưu trữ toàn bộ lịch sử thay đổi cấu hình hạ tầng. Việc tách biệt luồng này cho phép hệ thống thực hiện đối soát kỹ thuật (Engineering Audit) bất cứ khi nào có sự sai lệch giữa tọa độ thực địa và dữ liệu hệ thống, đồng thời duy trì kho dữ liệu lịch sử bền vững phục vụ cho các báo cáo kiểm toán và phân tích xu hướng thay đổi hạ tầng trong dài hạn.

3.3 Module 2: Kiểm soát chất lượng dữ liệu (Data Quality Check)



Hình 3.3: Module Data Quality Check

Phân hệ kiểm soát chất lượng dữ liệu (DQC) đóng vai trò như một bộ lọc nhiễu tự động và là cơ chế ngắt mạch an toàn (*Circuit Breaker*) nhằm loại bỏ các dị biệt vật lý từ thiết bị đầu cuối, bảo vệ tính đúng đắn cho các mô hình phân tích phía sau.


- **Khung kiểm định đa chiều (GX Framework):** Hệ thống tích hợp trực tiếp thư viện Great Expectations (GX) trên nền PySpark DataFrame để thực thi kiểm tra song song dữ liệu ngay trên bộ nhớ RAM của cụm máy chủ theo 5 chiều tiêu chuẩn:

1. *Đầy đủ (Completeness):* Đảm bảo không khuyết thiếu các trường thông tin sống còn như tọa độ địa lý, Cell ID, mốc thời gian và chỉ số RSRP.
2. *Hợp lệ (Validity):* Kiểm tra các trường dữ liệu tuân thủ đúng định dạng và kiểu cấu trúc quy định.
3. *Chính xác (Accuracy):* Đảm bảo giá trị cường độ sóng RSRP nằm trong giới hạn vật lý kỹ thuật viễn thông cho phép (từ -140 dBm đến -40 dBm).
4. *Duy nhất (Uniqueness):* Loại bỏ hoàn toàn các bản ghi trùng lặp mã định danh duy nhất của phiên đo trong cùng một khung thời gian.
5. *Kịp thời (Timeliness):* Kiểm tra xem dữ liệu có tới đúng vào khung giờ đang cập nhật dữ liệu hay không .

- **Xử lý nhiễu tọa độ vật lý (GPS Drift Isolation) (Validity):** Phân hệ ứng dụng thuật toán khoảng cách dựa trên quy tắc thống kê hình học phổ quát (*3-Sigma Threshold*) nhằm phát hiện và cô lập các điểm đo có tọa độ bị nhảy cóc hoặc sai lệch nghiêm trọng do mất tín hiệu định vị vệ tinh của thiết bị người dùng di chuyển.
- **Nhất quán tham chiếu:** Kết nối dữ liệu log MDT với dữ liệu trạm phát xem có định danh trạm nào không có hay có nhưng theo danh sách trạm mới nhất thì không còn nữa. Những trường hợp này sẽ đánh dấu là dữ liệu "dirty" và đẩy vào phân vùng "dirty data".
- **Cơ chế Circuit Breaker tự động:** Trong quá trình kiểm định, nếu công cụ GX ghi nhận tỷ lệ số lượng bản ghi vi phạm vượt quá ngưỡng dung sai cấu hình (20%), Apache Airflow sẽ ngay lập tức kích hoạt cơ chế ngắt mạch tự động, dừng toàn bộ tiến trình xử lý tiếp theo của Pipeline xử lý giờ đó và bắn cảnh báo khẩn cấp tới đội ngũ kỹ sư vận hành để kiểm tra lỗi hệ thống nguồn.
- **Phân tầng dữ liệu tinh sạch (Silver Layer):** Dữ liệu vượt qua bộ lọc chất lượng được dán nhãn an toàn và chuyển tiếp sang tầng **Silver Layer**. Toàn bộ các bản ghi lỗi bị loại bỏ sẽ được chuyển hướng tự động sang vùng lưu trữ cách ly (*Quarantine/Dirty Data Store*) để lưu vết phục vụ cho tác vụ phân tích, hậu kiểm và lập báo cáo kiểm toán chất lượng dữ liệu (*Quality Audit Report*).

3.4 Module 3: Nội suy không gian (Spatial Modeling)


Module này giải quyết bài toán cốt lõi của đề tài: chuyển đổi không gian biểu diễn từ các điểm tọa độ địa lý rời rạc mang tính ngẫu nhiên cao thành mô hình phân vùng địa lý lưới đồng nhất, loại bỏ nhiễu cục bộ và cho phép thực hiện tính toán mật độ.



Hình 3.4: Ví dụ về phân vùng địa lý H3

- Thuật toán mã hóa không gian chuẩn Uber H3:** Hệ thống áp dụng thuật toán băm địa lý dựa trên thư viện mã nguồn mở Uber H3 thông qua các hàm định nghĩa người dùng tối ưu hóa (*PySpark UDF*). Cặp tọa độ liên tục (*Latitude, Longitude*) của điểm đo sạch từ tầng Silver được tính toán ánh xạ chính xác thành một mã chỉ số lục giác duy nhất *h3_index*. Hệ thống lựa chọn cấu hình độ phân giải **Resolution 9** (tương ứng với diện tích bề mặt mỗi ô lục giác xấp xỉ $0.1km^2$). Đây là độ phân giải lý tưởng, tương thích hoàn toàn với bán kính phủ sóng và vùng phục vụ thực tế của các trạm phát sóng viễn thông tại các khu vực đô thị có mật độ cao.
- Tối ưu hiệu năng bộ nhớ bằng Broadcast Join:** Khi thực hiện liên kết dữ liệu điểm đo MDT (bảng dữ liệu lớn có quy mô hàng triệu dòng) với bảng cấu hình kỹ thuật tọa độ vị trí trạm phát (*Cell Configuration* - bảng chiều kích thước nhỏ), thao tác kết nối truyền thông sẽ gây ra hiện tượng xáo trộn dữ liệu qua mạng lưới (*Network Shuffling*), dẫn đến nghẽn cổ chai hiệu năng hoặc lỗi tràn bộ nhớ (*Out-Of-Memory*). Để xử lý triệt để vấn đề này, hệ thống áp dụng kỹ thuật *Broadcast Join*. Toàn bộ bảng dữ liệu cấu hình trạm phát được nhân bản và đẩy sẵn vào bộ nhớ RAM đệm của tất cả các Node thợ (*Worker Nodes*) trong cụm Spark Cluster. Giải pháp giúp quá trình tra cứu thông tin trạm phát diễn ra tức thì tại chỗ, tối ưu hóa tốc độ xử lý của Spark lên gấp nhiều lần. Đầu ra là tập dữ liệu điểm đo được làm giàu thông tin không gian hoàn chỉnh.

3.5 Module 4: Thiết kế mô hình dữ liệu (Gold Layer)




Hình 3.5: Module Data Modeling

Mục tiêu của module này là tổ chức, cấu trúc hóa dữ liệu tại tầng thành phẩm thành mô hình lưu trữ tối ưu hóa cho các tác vụ phân tích dữ liệu lớn và truy vấn tổng hợp khối lượng lớn (OLAP) với độ trễ cực thấp.


- **Tính toán gom cụm (Aggregation Engine):** Sử dụng công cụ PySpark thực thi tác vụ *groupBy* diện rộng dựa trên khóa tổ hợp định vị không gian và thời gian bao gồm: (*h3_index*, *cell_id*, *date_hour*). Hệ thống tính toán song song các chỉ số KPI chất lượng mạng cốt lõi cho từng ô lưới: Cường độ trường trung bình *avg_rsrp*, mức phân vị 10 để nhận diện ngưỡng sóng tối *p10_rsrp*, khoảng cách truyền sóng trung bình *avg_distance_km*, và tổng số thiết bị hoạt động độc lập nhằm xác định mật độ người dùng (*User Density Count*).
- **Mô hình hóa hình sao (Star Schema):** Dữ liệu thành phẩm được lưu trữ cố định xuống tầng **Gold Layer** tuân thủ nghiêm ngặt theo mô hình lược đồ hình sao (Star Schema) như mô tả trong hình 3.6. Cấu trúc bao gồm một bảng thực thể trung tâm (**Fact Table**): *fact_mdt_hourly* chứa các chỉ số đo lường biến động liên tục, liên kết chặt chẽ với các bảng chiều thông tin kích thước tính (**Dimension Tables**) bao gồm bảng không gian lục giác (*dim_h3*), bảng thông số trạm phát vô tuyến (*dim_cell*), và bảng niên lịch thời gian (*dim_calendar*).
- **Đăng ký Schema và Quản lý Bảng cấu hình Trạm với SCD Type 1:** Để cấu trúc dữ liệu Delta Lake tại tầng Gold có thể dễ dàng truy cập bởi các công cụ bên

ngoài, hệ thống tiến hành đăng ký cấu trúc bảng (*register_table*) tập trung thông qua lớp lưu trữ siêu dữ liệu Hive Metastore. Đặc biệt, đối với dữ liệu bảng chiều Trạm (*dim_cell*), do thông số hạ tầng viễn thông có tần suất thay đổi rất thấp theo thời gian, hệ thống áp dụng chiến lược tối ưu hóa bảng chiều thay đổi chậm loại 1 (**SCD Type 1**). Khi có sự thay đổi về tọa độ hoặc góc nghiêng, góc ngả anten (Tilt/Azimuth), hệ thống sử dụng cú pháp toán tử *MERGE INTO* trên Delta Lake để ghi đè trực tiếp trạng thái mới nhất lên dòng dữ liệu cũ dựa theo mã *cell_code*. Giải pháp SCD Type 1 giúp giữ kích thước bảng chiều luôn ở mức tối giản, cho phép nạp trọn vẹn bảng vào bộ nhớ RAM của Worker Node, triệt tiêu hoàn toàn các phép Join phức tạp theo khoảng thời gian hiệu lực và đảm bảo tốc độ phản hồi truy vấn của Trino Engine đạt mức dưới giây (sub-second).



Hình 3.6: Mô hình dữ liệu Star Schema tại tầng Gold.

3.6 Module 5: Dự báo và cảnh báo sớm (Forecasting & Warning)



Hình 3.7: Module Dự báo và cảnh báo

Phân hệ Dự báo và Cảnh báo sớm đóng vai trò then chốt trong việc chuyển đổi hệ thống G-SQM từ cơ chế giám sát thụ động (chỉ ghi nhận sự cố sau khi đã xảy ra) sang mô hình giám sát chủ động. Phân hệ này cung cấp tầm nhìn đi trước thời gian, cho phép nhận diện và có phương án tối ưu các phân vùng không gian có nguy cơ suy hao tín hiệu hoặc quá tải trước khi chúng thực sự gây ảnh hưởng đến trải nghiệm người dùng cuối.

3.6.1 Mô hình dự báo chuỗi thời gian Prophet

Để giải quyết bài toán dự báo cho dữ liệu viễn thông, hệ thống không sử dụng các mô hình học máy truyền thống mà lựa chọn thuật toán **Prophet** (được nghiên cứu và phát triển bởi Meta). Đây là mô hình hồi quy cộng tính (Additive Regression Model), biểu diễn dưới dạng công thức $y(t) = g(t) + s(t) + h(t) + \epsilon_t$. Sự lựa chọn này dựa trên 3 đặc tính ưu việt hoàn toàn khớp với bản chất dữ liệu mạng lưới:

- **Nắm bắt chu kỳ đa tầng (Multiple Seasonality):** Lưu lượng và chất lượng tín hiệu viễn thông mang tính tuần hoàn rất mạnh. Prophet có khả năng mô hình hóa chính

xác các chu kỳ chồng chéo này, bao gồm chu kỳ theo giờ trong ngày (ngày/đêm) và chu kỳ theo ngày trong tuần (ngày làm việc/cuối tuần).

- **Khả năng chống nhiễu (Robustness to Outliers):** Dữ liệu log MDT trong thực tế thường xuyên xuất hiện các điểm nhiễu (outliers) hoặc bị khuyết thiếu (missing data) do lỗi truyền dẫn từ thiết bị. Khác với các mô hình như ARIMA vốn rất nhạy cảm với dữ liệu khuyết, Prophet linh hoạt bỏ qua các nhiễu cục bộ này để duy trì xu hướng (trend) dự báo chính xác.
- **Cung cấp khoảng tin cậy (Confidence Intervals):** Thay vì chỉ đưa ra một giá trị dự đoán điểm (Point estimate), Prophet cung cấp dải dự báo bao gồm cận trên (*yhat_upper*) và cận dưới (*yhat_lower*). Đây là cơ sở toán học vững chắc để hệ thống xây dựng các ngưỡng cảnh báo tự động thay vì phải gán ngưỡng (hard-code) thủ công.

3.6.2 Huấn luyện phân tán và tối ưu hóa tài nguyên

Vì hệ thống G-SQM muốn phân tích được chuyên biệt tới từng phân vùng địa lý nhằm có một cách đánh giá toàn diện. Do đó, yêu cầu đặt ra là phải huấn luyện hàng ngàn mô hình dự báo độc lập cho từng phân vùng H3 thay vì một mô hình tổng quát.

Để giải quyết bài toán khối lượng tính toán khổng lồ này, G-SQM triển khai kiến trúc học máy phân tán trên cụm Spark:

- **Dữ liệu đầu vào:** Dữ liệu đầu vào (lịch sử 7 ngày từ tầng Gold) được nhóm theo trường không gian thông qua thao tác *repartition(h3_index)*. Quá trình này được can thiệp phân vùng thủ công nhằm duy trì quyền kiểm soát chặt chẽ đối với hiện tượng lệch dữ liệu (Data Skew) ở các trạm có lưu lượng cực lớn, giúp hệ thống phân phối tải đồng đều đến các Node thợ (Worker Nodes) và triệt tiêu hoàn toàn rủi ro tràn bộ nhớ (Out of Memory - OOM) thay vì phụ thuộc vào cơ chế tự động của Spark.
- **Song song hóa với *applyInPandas*:** Thông qua toán tử *applyInPandas* của PySpark, hệ thống Vector hóa quá trình huấn luyện. Hàng ngàn mô hình Prophet được kích hoạt chạy song song trên toàn cụm. Dù luồng dự báo được em bật DAG thủ công nhưng cơ chế Massively Parallel Processing (MPP) này mang lại khả năng mở rộng (High Scalability) vô hạn, hướng tới cho phép hoàn tất dự báo 24 giờ tiếp theo cho toàn mạng lưới cấp tỉnh chỉ trong một khung giờ thấp điểm (ví dụ: 01:00 AM).

3.6.3 Cơ chế cảnh báo sớm tự động


Kết quả đầu ra từ các tiến trình huấn luyện được ghi trực tiếp vào bảng *fact_forecast_hourly*. Tại đây, engine truy vấn Trino SQL đóng vai trò là cốt lõi của module cảnh báo:

- Hệ thống liên tục đối chiếu luồng dữ liệu thực tế (Actual Data) thu thập được ở hiện tại với dải dự báo (Forecast Bounds) đã tính toán từ đêm hôm trước.
- Nếu chỉ số Cường độ tín hiệu thu tham chiếu (RSRP) thực tế vượt qua ngưỡng cận dưới (*yhat_lower*), hoặc Mật độ người dùng (User Density) vượt quá ngưỡng cận trên (*yhat_upper*), Trino SQL sẽ ngay lập tức kích hoạt nhãn bất thường (Anomaly Flag).
- Nhãn này lập tức được đẩy lên hiển thị trực quan trên bản đồ luồng của Dashboard Kepler.gl, đồng thời kích hoạt Airflow gửi báo cáo Email tự động đến đội ngũ kỹ sư vận hành để tiến hành lên kế hoạch tối ưu kịp thời.

3.7 Hệ thống điều phối luồng công việc (Airflow Pipelines)

Để đảm bảo tính tự động hóa và quản lý sự phụ thuộc phức tạp giữa các tiến trình, toàn bộ hoạt động của G-SQM được điều phối bởi Apache Airflow thông qua 4 luồng công việc (DAGs) chính:

- **Luồng cập nhật cấu hình trạm (*dim_cell_update*):** Được thiết lập chạy thủ công hoặc khi có thay đổi (Event-driven). Luồng này trích xuất tệp danh mục trạm (Cell Info) từ máy chủ SFTP, đẩy lên vùng Bronze(MinIO) và kích hoạt PySpark cập nhật bảng chiều *dim_cell* theo cơ chế SCD Type 1, đảm bảo dữ liệu cấu hình luôn ở phiên bản mới nhất.
- **Luồng xử lý không gian cốt lõi (*mdt_spatial_analytics_pipeline*):** Chạy tự động với tần suất 1 giờ/lần (*@hourly*). Đây là đường ống xương sống (Backbone) của hệ thống, thực thi tuần tự các tác vụ từ tải dữ liệu thô từ SFTP (Ingestion) → Kiểm soát chất lượng (Silver Layer) → Băm tọa độ H3 và tạo lược đồ hình sao (Gold Layer) → Đăng ký bảng phục vụ truy vấn trên Trino.
- **Luồng dự báo đa biến (*mdt_daily_prophet_forecast*):** Khởi chạy để tính toán xu hướng cường độ sóng và mật độ người dùng. DAG này được thiết kế để tối ưu hóa bộ nhớ RAM trên Spark thông qua việc bật cấu hình Apache Arrow và giới hạn



Hình 3.8: DAGs

phân vùng (*shuffle partitions*), đồng thời tự động đánh giá các chỉ số của ngày hôm trước so với thực tế.

- **Luồng cảnh báo tự động (*mdt_alert_system_via_ui*):** Vận hành tự động hàng giờ (*@hourly*). Tác vụ Python thực hiện truy vấn SQL song song dữ liệu giám sát hiện tại và dữ liệu dự báo trên Trino Engine. Nếu phát hiện các phân vùng H3 bị lỗi liên tục (trong 3 giờ) hoặc có nguy cơ suy giảm chất lượng đột ngột trong 1 giờ tới, hệ thống tự động xuất báo cáo HTML và gửi Email cảnh báo qua giao thức SMTP tới đội ngũ vận hành.

Chương 4

Thực nghiệm

Chương này trình bày trình tự các thực nghiệm, các cấu hình cài đặt và kết quả tương ứng nhằm chứng minh tính khả thi và hiệu quả của hệ thống G-SQM. Em sẽ đi từ việc phân tích đặc tả tập dữ liệu, môi trường triển khai, cho đến kết quả thực thi của từng phân hệ (module) lõi trong Data Lakehouse và Dashboard trực quan.

4.1 Phân tích tập dữ liệu thực nghiệm

Dữ liệu sử dụng trong các thực nghiệm của dự án này được thu thập và mô phỏng theo dữ liệu log MDT (Minimization of Drive Tests) thực tế tại mạng lưới viễn thông, tập trung vào phân vùng tỉnh Thái Nguyên và một số khu vực lân cận.

Đặc tả luồng dữ liệu đầu vào:

- **Tần suất cập nhật:** Dữ liệu khoảng 100 nghìn bản ghi/giờ được hệ thống tự động trích xuất (*fetch*) (Hourly Batch). Đây là tần suất tối ưu đối với hạ tầng Data Lakehouse, đảm bảo hệ thống cung cấp góc nhìn tổng quan theo từng khung giờ không gây quá tải cho hệ thống.
- **Cấu trúc dữ liệu thô:** Tập log MDT bao gồm các trường thông tin cơ bản: mã thiết bị ẩn danh (*device_code*), mã trạm phục vụ (*cell_code*), tọa độ địa lý (*lat*, *lng*), và các chỉ số vô tuyến (*p_cell_rsrp*, *p_cell_rsrq*). Cùng với đó là bộ dữ liệu từ điển Trạm phát (*Cell Configuration*) chứa tọa độ trạm vật lý.
- **Khối lượng dữ liệu:** Trong môi trường thực nghiệm, dữ liệu một ngày đang có khoảng 1,5 đến 2 triệu bản ghi. Sau quá trình lọc nhiễu và băm không gian (Spatial Hashing), các điểm đo này được ánh xạ vào hàng ngàn phân vùng lục giác H3

(Resolution 9), tạo ra một khối lượng dữ liệu khổng lồ theo thời gian (Time-series Big Data).

4.2 Môi trường và cấu hình thực nghiệm


Để đáp ứng khối lượng dữ liệu log MDT (Minimization of Drive Tests) khổng lồ và yêu cầu xử lý phân tán, hệ thống G-SQM được triển khai trên nền tảng kiến trúc **Data Lakehouse**, cho phép kết hợp khả năng lưu trữ linh hoạt của Data Lake với hiệu năng truy vấn của Data Warehouse. Cấu hình chi tiết các tầng bao gồm:

- **Tầng Lưu trữ (Storage Layer):** Sử dụng **MinIO S3** làm Data Lake chính để lưu trữ dữ liệu thô và đã tinh chế dưới định dạng mở **Delta Lake**. Định dạng này đóng vai trò quan trọng trong việc đảm bảo tính toàn vẹn (ACID) cho các giao dịch ghi/đọc dữ liệu lớn và hỗ trợ đánh chỉ mục hiệu quả.
- **Tầng Xử lý (Compute Engine):** **Apache Spark** được sử dụng làm động cơ xử lý cốt lõi. Với cấu hình bộ nhớ khiêm tốn với `driver.memory=4g`, `executor.memory=4g`, hệ thống thực hiện song song hóa các tác vụ phức tạp:
 - *Phân vùng không gian:* Sử dụng thư viện **H3 (Uber)** để gán nhãn không gian cho các tọa độ địa lý.
 - *Huấn luyện mô hình:* Triển khai **Prophet** theo cơ chế `applyInPandas` trên Spark để dự báo đa biến (mật độ User và cường độ RSRP) tại từng phân vùng.
- **Tầng Siêu dữ liệu & Điều phối (Metadata & Orchestration):** **Apache Airflow** đảm nhận vai trò điều phối các luồng dữ liệu (Data Pipelines) thông qua các DAGs tự động. **Hive Metastore** kết hợp cùng Delta Lake giúp quản lý lược đồ bảng (Schema), đảm bảo tính nhất quán cho dữ liệu từ tầng Bronze đến Gold.
- **Tầng Truy vấn & Phục vụ (Serving Layer):** **Trino** được cấu hình kết nối trực tiếp vào Data Lake thông qua Hive Metastore, phục vụ các truy vấn OLAP siêu tốc phục vụ nhu cầu tra cứu thời gian thực của ứng dụng.
- **Tầng Ứng dụng (Frontend):** Giao diện được xây dựng bằng **Streamlit**, tích hợp **Kepler.gl** để trực quan hóa bản đồ không gian WebGL và **Chart.js** để hiển thị các chỉ số dự báo, giúp kỹ sư vận hành dễ dàng nhận diện vùng lõm sóng hoặc điểm nghẽn.

Toàn bộ hệ thống được container hóa bằng **Docker/Docker Compose**, đảm bảo sự đồng nhất tuyệt đối giữa môi trường phát triển và môi trường triển khai thực tế.

4.3 Kết quả thực nghiệm

4.3.1 Kết quả thực nghiệm module thu thập dữ liệu



Hình 4.1: Kết quả thực nghiệm module thu thập dữ liệu qua MinIO storage


Đầu ra mong muốn của module thu thập dữ liệu (Data Ingestion) là việc trích xuất thành công log MDT từ máy chủ SFTP và nạp an toàn vào tầng Bronze trên hệ thống lưu

trữ MinIO. Hình 4.1 thể hiện dữ liệu thô đã được lưu trữ thành công tại đường dẫn *bronze/mdt_raw* và được hệ thống phân vùng (partition) rõ ràng theo từng ngày, ví dụ như *batch_date=2025-05-04* hay *batch_date=2025-05-06*.


Như đã nhắc đến ở các phần trước, khoảng cách giữa 2 lần chạy liên tiếp của Airflow DAG được thiết lập là 1 giờ (*Hourly Batch*). Từ các biểu đồ thống kê thời gian thực thi (Task Instance Duration) trên giao diện Apache Airflow, có thể thấy module thu thập hoạt động cực kỳ nhanh chóng và ổn định. Cụ thể, tác vụ trích xuất dữ liệu từ SFTP về vùng đệm (*0_fetch_sftp_to_minio*) chỉ mất thời gian trung bình (median) là 21.27 giây. Tác vụ tiếp theo chịu trách nhiệm nạp dữ liệu vào định dạng Delta Lake tại tầng Bronze (*1_ingest_to_bronze*) cũng chỉ tiêu tốn trung bình 40.69 giây.

Như vậy, toàn bộ quá trình của module này chỉ mất tầm khoảng 1 phút để hoàn tất việc thu thập hàng triệu bản ghi cho mỗi ca (giờ). Hệ thống hoàn toàn không gặp phải hiện tượng nghẽn cổ chai hay độ trễ mạng lớn, đảm bảo dữ liệu luôn được chuẩn bị sẵn sàng và đúng hạn cho các phân hệ kiểm định và phân tích phía sau.


4.3.2 Kết quả thực nghiệm module kiểm soát chất lượng (Data Quality Check)



Hình 4.2: Cấu trúc phân loại dữ liệu tại tầng Silver trên hệ thống MinIO.



Hình 4.3: Dữ liệu sạch (mdt_clean) được lưu trữ dưới định dạng Delta Lake và phân vùng theo ngày.



Hình 4.4: Thời gian thực thi tác vụ kiểm soát chất lượng (2_run_quality_check) trên Apache Airflow.


Đầu ra mong muốn của module kiểm soát chất lượng là tự động đánh giá, lọc nhiễu và phân loại thành công dữ liệu thô từ tầng Bronze, sau đó nạp lên tầng Silver một cách

an toàn. Hình 4.2 cho thấy dữ liệu sau khi đi qua thư viện Great Expectations và bộ lọc không gian đã được phân tách rõ ràng thành ba thư mục chuyên biệt tại vùng *silver* trên hệ thống MinIO: *mdt_clean* (chứa dữ liệu sạch), *dirty_data* (cách ly dữ liệu lỗi), và *quality_report* (lưu trữ báo cáo chất lượng). Truy cập chi tiết vào thư mục *mdt_clean* (Hình 4.3), có thể thấy dữ liệu được tổ chức chuẩn trị dưới định dạng Delta Lake và được hệ thống phân vùng (partition) rãnh mạch theo từng ngày, ví dụ như *date=2025-05-04* hay *date=2025-05-06*.


Về mặt hiệu năng, quá trình quét và kiểm định hàng triệu bản ghi cho mỗi ca (giờ) diễn ra vô cùng tối ưu. Dựa trên biểu đồ thống kê thời gian thực thi (Task Instance Duration) từ giao diện Apache Airflow (Hình 4.4), có thể thấy module kiểm soát chất lượng hoạt động cực kỳ nhanh chóng và ổn định. Cụ thể, tác vụ chịu trách nhiệm thực thi các luật kiểm định (*2_run_quality_check*) chỉ mất thời gian trung bình (median) là 1.63 phút.

Như vậy, toàn bộ quy trình kiểm soát chất lượng phức tạp chỉ tiêu tốn chưa tới 2 phút để hoàn tất việc sàng lọc hàng triệu bản ghi cho mỗi ca (giờ). Hệ thống hoàn toàn không gặp phải hiện tượng nghẽn cổ chai, đảm bảo loại bỏ kịp thời các dữ liệu rác (như lỗi trôi tọa độ GPS) và giữ cho luồng dữ liệu sạch luôn sẵn sàng, đạt độ tin cậy tuyệt đối cho các phân hệ nội suy không gian và phân tích phía sau.

4.3.3 Kết quả thực nghiệm module thiết kế mô hình dữ liệu (Data Modeling)



Hình 4.5: Dữ liệu bảng Fact (fact_mdt_hourly) được lưu trữ chuẩn hóa tại tầng Gold trên MinIO.



Hình 4.6: Thời gian thực thi tác vụ xây dựng mô hình dữ liệu (3_build_fact_model) trên Apache Airflow.

Đầu ra mong muốn của module thiết kế mô hình dữ liệu là thực hiện băm địa lý (Spatial Hashing) tọa độ thành mã lục giác H3, tính toán không gian và tổng hợp dữ liệu thành

cấu trúc Lược đồ hình sao (Star Schema) tại tầng Gold để tối ưu hóa khả năng truy vấn đa chiều (OLAP). Hình 4.5 thể hiện kết quả dữ liệu sau khi được tổng hợp đã lưu trữ thành công tại vùng *gold/fact_mdt_hourly* trên hệ thống MinIO. Có thể quan sát thấy dữ liệu bảng Fact đã được tổ chức chuẩn trị dưới định dạng Delta Lake và hệ thống tự động phân vùng (partition) rãnh mạch theo từng ngày, ví dụ như *date=2025-05-04* hay *date=2025-05-06*.

Về mặt hiệu năng, đây là một trong những tác vụ tính toán hạng nặng nhất của đường ống dữ liệu do Spark phải thực hiện các phép toán kết hợp (Join) và gom cụm (Aggregation) để tính toán các KPI như mật độ người dùng (*user_density_count*) và cường độ sóng trung bình (*avg_rsrp*) trên hàng triệu bản ghi. Tuy nhiên, dựa trên biểu đồ thống kê thời gian thực thi (Task Instance Duration) từ giao diện Apache Airflow (Hình 4.6), tác vụ này (*3_build_fact_model*) ghi nhận tốc độ xử lý cực kỳ ấn tượng. Cụ thể, thời gian thực thi trung bình (median) chỉ đạt 0.96 phút (khoảng 57 giây). Mặc dù có một vài thời điểm xuất hiện các đỉnh (spikes) xử lý kéo dài lên khoảng 5-6 phút do đặc thù lượng dữ liệu mạng lưới dồn về lớn vào các khung giờ cao điểm, mức hiệu suất tổng thể vẫn vô cùng ổn định và được kiểm soát tốt.


Như vậy, toàn bộ quá trình biến đổi, gom cụm và thiết kế mô hình dữ liệu hình sao chỉ tiêu tốn trung bình xấp xỉ 1 phút để hoàn tất cho mỗi ca (giờ) dữ liệu. Hệ thống đã chứng minh được sức mạnh xử lý phân tán xuất sắc, đảm bảo lớp dữ liệu Gold luôn được làm mới nhanh chóng, cung cấp một nền tảng dữ liệu vững chắc và sẵn sàng cho các mô hình dự báo cũng như hiển thị tốc độ cao trên giao diện Dashboard.

4.3.4 Kết quả thực nghiệm module cảnh báo

Module cảnh báo trong hệ thống G-SQM được thiết kế để cung cấp cái nhìn toàn diện không chỉ về tình trạng vùng phủ sóng (RSRP) và mật độ người dùng hiện tại, mà còn đưa ra các cảnh báo rủi ro dựa trên dữ liệu không gian tiệm cận thời gian thực. Kết quả thực nghiệm của module này được trực quan hóa và quan sát trực tiếp thông qua hệ thống Dashboard Streamlit kết hợp bản đồ không gian Kepler.gl.

Hình 4.7 mô tả giao diện cảnh báo tổng quan của hệ thống. Thay vì đánh giá trung bình theo trạm phát (Cell ID), hệ thống tự động bóc tách và khoanh vùng các ô lục giác H3 gặp sự cố. Bảng rôn cảnh báo (Báo động đỏ) sẽ tự động xuất hiện trên màn hình nếu hệ thống phát hiện các phân vùng duy trì trạng thái lồi sóng ($RSRP < -100$ dBm) liên tục trong 3 giờ. Ngược lại, nếu mạng lưới ổn định, hệ thống sẽ hiển thị thông báo an toàn.


Hơn thế nữa, module cảnh báo kết hợp chặt chẽ với module dự báo để sinh ra các "Cảnh báo sớm"(Hình 4.8). Thông qua việc phân tích khoảng tin cậy của dữ liệu dự đoán, nếu đường tín hiệu RSRP có xu hướng đâm thủng biên dưới an toàn trong khi mật độ người dùng tăng cao đột biến, hệ thống sẽ tự động dán nhãn nguy cơ và khoanh vùng các điểm lồi sóng dự kiến trong 1 giờ tới. Các danh sách này không chỉ hiển thị trên giao diện mà còn được tự động kích hoạt luồng gửi Email/SMS đến các kỹ sư tối ưu mạng lưới (Hình 4.9), đảm bảo tính chủ động trong công tác vận hành.



Hình 4.7: Giao diện cảnh báo vùng lồi sóng tối liên tục (màu đỏ) trên Dashboard.



Hình 4.8: Bản đồ không gian tự động highlight các phân vùng H3 lốm sọc trong vòng 3 tiếng liên tục.




Hình 4.9: Email tự động cảnh báo các bất thường

4.3.5 Kết quả thực nghiệm module dự báo & cảnh báo sớm

Module dự báo được thực nghiệm và kiểm chứng qua hai tiêu chí chính: khả năng bám sát chu kỳ thời gian thực tế hiển thị trên Dashboard và độ tin cậy thống kê của mô hình học máy Prophet khi dự đoán hai trường dữ liệu cốt lõi là Cường độ tín hiệu (RSRP) và Lưu lượng người dùng (User Density).

Dự đoán và hiển thị trên dashboard



Hình 4.10: Giao diện cảnh báo sớm các vùng tối (màu vàng) trên Dashboard.

Các biểu đồ bên phải hình 4.10 biểu diễn mức độ biến động mật độ người dùng và RSRP tại một phân vùng cụ thể. Đường nét đứt đại diện cho rủi ro bùng phát tối đa (Upper Bound) đối với mật độ, và biên độ nhiễu suy hao sóng (Lower Bound) đối với RSRP. Quan sát đồ thị có thể thấy mô hình Prophet đã học và nắm bắt rất tốt tính chu kỳ (Seasonality) của mạng lưới viễn thông: mật độ người dùng thường sụt giảm vào ban đêm và tăng vọt vào các khung giờ cao điểm (sáng và chiều tối). Sự kết hợp giữa đường dự báo và đường thực tế giúp kỹ sư dễ dàng đối chiếu và nhận diện ngay lập tức nếu tải hệ thống đang vượt quá ngưỡng an toàn được dự đoán.

Đánh giá mô hình dự báo

Để đánh giá định lượng hiệu suất của mô hình Prophet trên quy mô hàng ngàn phân vùng H3, chúng tôi sử dụng hai thang đo sai số phổ biến: Sai số tuyệt đối trung bình (MAE) và Căn bậc hai sai số toàn phương trung bình (RMSE).

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Trong đó:


- y_t : Giá trị thực tế thu thập từ log MDT.
- $\hat{y}_t$: Giá trị dự đoán từ mô hình Prophet.
- n : Tổng số điểm dữ liệu trong tập kiểm định.

Kết quả kiểm định thực tế trên toàn mạng lưới tỉnh Thái Nguyên cho thấy các giá trị sai số của mô hình nằm trong ngưỡng chấp nhận được và phản ánh đúng bản chất của từng loại dữ liệu.


Đối với bài toán dự báo lưu lượng người dùng, sai số lệch trung bình (MAE) đạt 18.56 người/phân vùng, và RMSE đạt 41.39. Việc chỉ số RMSE cao hơn hẳn so với MAE cho thấy mô hình phải đối mặt với biên độ dao động lớn do tính chất ngẫu nhiên trong hành vi di chuyển của con người. Mật độ người dùng tại một ô lục giác nhỏ phụ thuộc vào rất nhiều yếu tố động như tình trạng giao thông, các sự kiện tập trung đông người bùng phát hoặc thay đổi thói quen sinh hoạt theo mùa, khiến việc dự báo chính xác tuyệt đối số lượng người luôn là một bài toán thách thức.

Ngược lại, đối với cường độ sóng RSRP, mô hình cho kết quả ổn định hơn với MAE đạt 5.14 dBm và RMSE ở mức 10.04 dBm. Xét trong môi trường vô tuyến, nơi cường độ tín hiệu RSRP thực tế biến thiên liên tục trong một dải rộng (thường dao động từ khoảng -40 dBm đến -140 dBm, tức là biên độ lệch lên tới 100 dBm), mức sai số dao động trong khoảng 5 đến 10 dBm là hoàn toàn chấp nhận được và có giá trị thực tiễn cao. Kết quả này khả quan là do RSRP mang bản chất của một đại lượng vật lý; bên cạnh nhiễu động tức thời, nó phụ thuộc chặt chẽ vào khoảng cách tới trạm phát, cấu trúc địa hình và mô hình truyền sóng cố định của từng phân vùng địa lý — những đặc trưng có tính lặp lại cao và dễ học hơn đối với mô hình chuỗi thời gian.

Sự tương quan trực quan giữa đường dự báo và đường thực tế tại một số trạm đo được thể hiện chi tiết tại Đồ thị ở Hình 4.11.



(a) Biến động Mật độ người dùng



(b) Biến động Cường độ tín hiệu RSRP

Hình 4.11: Biểu đồ chuỗi thời gian hiển thị dự báo biến động trong 24H.

Phân tích lỗi và thách thức dữ liệu

Dù mô hình đem lại kết quả khả quan, quá trình thực nghiệm G-SQM cũng ghi nhận một số nguyên nhân gây ra sai số dự báo, chủ yếu xuất phát từ đặc thù của nguồn dữ liệu thô (MDT Logs):


Thứ nhất là hiện tượng "khuyết dữ liệu" (Missing Data) tại các vùng thưa dân hoặc vào khung giờ đêm muộn (01:00 AM - 05:00 AM). Do MDT thu thập log từ thiết bị người dùng cuối, nếu không có thuê bao nào hoạt động tại một ô lục giác H3, hệ thống sẽ không ghi nhận được chỉ số RSRP. Điều này tạo ra các khoảng trống (gaps) trong chuỗi thời gian, buộc mô hình Prophet phải thực hiện phép nội suy, làm giảm độ chính xác cục bộ tại các khung giờ đó.

Thứ hai là hiện tượng sai số định vị (GPS Drift). Trong môi trường đô thị dày đặc hoặc di chuyển tốc độ cao, thiết bị có thể gửi về tọa độ sai lệch. Mặc dù module Kiểm soát chất lượng (DQC) đã áp dụng thuật toán thống kê 3-Sigma để loại bỏ các điểm nhiễu loạn (outliers), một lượng nhỏ dữ liệu trôi dạt vẫn có thể lọt qua, khiến việc gom cụm mật độ H3 bị sai lệch nhẹ so với thực tế.

Cuối cùng, các sự kiện tập trung đông người mang tính bất ngờ (như lễ hội, tai nạn, sự kiện thể thao) gây ra các gai nhiễu (Spikes) đột biến về mật độ người dùng mà một mô hình học chu kỳ lịch sử như Prophet khó có thể dự báo chính xác hoàn toàn trước 24 giờ. Trong những trường hợp này, biên độ rủi ro (Upper Bounds) có thể bị đâm thủng, và hệ thống sẽ ngay lập tức chuyển quyền xử lý cho module cảnh báo thời gian thực thay vì chỉ phụ thuộc vào đường dự báo.

4.3.5.1 Phân tích hiệu năng luồng dự báo

Do hệ thống G-SQM được triển khai thử nghiệm trên một hạ tầng phần cứng có phần hạn chế về mặt tài nguyên phân bổ (cụ thể driver và executor của Apache Spark chỉ cấu hình ở mức bộ nhớ vật lý tối thiểu là 4GB RAM như đã thiết lập tại Mục 4.2), bài toán đảm bảo hiệu năng xử lý cho dòng chảy Big Data (vòng đời từ Bronze → Silver → Gold → Prophet Model) là một thách thức kỹ thuật rất lớn.




Hình 4.12: Biểu đồ phân phối thời gian thực thi (Task Duration) chi tiết của tác vụ chạy mô hình Prophet trên Apache Airflow.


Quan sát từ Hình 4.12, thời gian thực thi của tác vụ dự báo nhìn chung nằm trong tầm kiểm soát và đáp ứng được chu kỳ giờ (Hourly Batch) của tập dữ liệu thực nghiệm. Dù chưa phải là một cấu hình tối ưu cho môi trường sản xuất quy mô lớn, các giải pháp tinh chỉnh thủ công này bước đầu giúp hệ thống G-SQM tận dụng tốt tài nguyên hiện có, đảm bảo luồng dữ liệu chạy thông suốt mà không gặp lỗi dừng tiến trình đột ngột.

4.4 Dashboard trực quan hóa dữ liệu (Command Center)


Để giải quyết bài toán hiển thị và render đồ họa mượt mà cho hàng ngàn ô lưới lục giác 3D cùng lúc – điều mà các công cụ BI truyền thống thường gặp giới hạn về hiệu năng render hình khối – hệ thống G-SQM xây dựng giao diện ứng dụng Web Front-end chuyên biệt bằng thư viện **Streamlit**, đóng vai trò như một phòng điều phối trung tâm.



Hình 4.13: Giao diện Dashboard trực quan hóa dữ liệu vùng phủ G-SQM.



Hình 4.14: Giao diện Dashboard trực quan hóa dữ liệu vùng phủ G-SQM.




Hình 4.15: Chất lượng tín hiệu từng phân vùng.

Giao diện Dashboard được cấu trúc thành các khu vực chức năng mang tính tương tác cao:

- **Bảng điều khiển động (Sidebar Menu):** Cung cấp các widget cho phép người vận hành dễ dàng lọc dữ liệu theo ngày, trượt chọn cấu hình số giờ tối liên tục để định nghĩa ngưỡng nghiêm trọng, lựa chọn linh hoạt nguồn dữ liệu hiển thị (*Thực tế - MDT Actual* hoặc *Dự báo - Forecast*) và tìm kiếm đích danh theo mã ô lưới H3 hoặc Trạm phát sóng (Cell ID).
- **Hệ thống Thẻ Metric và Cảnh báo thông minh:** Phía trên cùng giao diện hiển thị các thẻ KPIs cốt lõi (Mật độ User, Khung giờ quét, RSRP trung bình toàn vùng hiển thị) có tính năng tự động tính toán mức chênh lệch tăng/giảm so với dữ liệu cùng khung giờ của tuần trước. Ngay phía dưới, hệ thống cung cấp 2 phân lớp cảnh báo tự động, đại diện cho hai mức độ trưởng thành của hệ thống:
 - *Cảnh báo tức thời (Báo động Đỏ - Reactive Action):* Là thành quả của tự động hóa luồng dữ liệu. Hệ thống bật thông báo lỗi màu đỏ rực nếu phát hiện các phân vùng đang bị lôm sôm nghiêm trọng kéo dài liên tục vượt quá số giờ cấu hình, yêu cầu kỹ sư phải can thiệp ngay lập tức.
 - *Cảnh báo sớm (Báo động Vàng - Proactive Action):* Là thành quả của mô

hình học máy Prophet. Hệ thống hiển thị bảng dữ liệu cảnh báo nguy cơ sạt sóng hoặc bùng phát tải trong 1 giờ tới, giúp kỹ sư có "thời gian vàng" để chủ động lên phương án tối ưu trước khi sự cố thực sự tác động đến người dùng.




Hình 4.16: Bản đồ

- **Bản đồ không gian tích hợp Kepler.gl đồ họa WebGL:** Bản đồ trung tâm sử dụng bộ framework Kepler.gl nhúng trong cấu trúc mã HTML của Streamlit. Bản đồ tổ chức xếp chồng nhiều lớp dữ liệu (*Layer Stacking*) một cách khoa học:



1. **MDT_Coverage_Live:** Hiển thị toàn bộ các ô lục giác H3 ánh xạ dải màu sắc liên tục từ Đỏ (Rất kém, < -110 dBm) qua Cam, Vàng đến Xanh đậm (Tốt, > -85 dBm).
2. **Highlight_Holes:** Tự động bóc tách và đổ màu Đỏ để khoanh vùng các phân vùng đang bị lõm sóng nghiêm trọng tại thời điểm hiện tại.
3. **Early_Warning_Layer:** Phủ lớp lục giác màu Vàng nổi bật lên các phân vùng H3 được thuật toán prophet dự báo sẽ có nguy cơ sóng yếu hoặc lõm sóng trong 1 tiếng tới.
4. **Arc Layers & Cell Point:** Vẽ các đường cung truyền sóng vật lý kết nối từ vị trí tâm trạm phát đến tâm các ô lục giác đo được, kết hợp góc phủ sóng (Azimuth), giúp kỹ sư phát hiện ngay các khu vực bị khuất sóng hoặc lệch hướng Anten.

5. *Tính năng Side-by-Side Comparison*: Khi kích hoạt công tắc so sánh đôi, giao diện tự động chia đôi màn hình thành hai bản đồ đồng bộ tọa độ chuột, cho phép đối chiếu trực quan biến động vùng phủ của ngày hiện tại so với tuần trước.



Hình 4.17: So sánh tuần này và tuần trước

- **Cửa sổ phân tích chuyên sâu (Network Insights)**: Được thiết kế dạng một panel nổi ở góc phải bản đồ, sử dụng thư viện Chart.js để biểu diễn các chiều thông tin chuyên sâu bao gồm ma trận nhiệt mật độ tải hệ thống tuần hoàn theo giờ và các ngày trong tuần (*Heatmap Matrix*) và biểu đồ đường chuỗi thời gian hiển thị rõ nét dải rủi ro an toàn biên độ nhiễu (*Upper/Lower bounds*) sinh ra từ mô hình Prophet, giúp kỹ sư đưa ra các quyết định tối ưu hạ tầng dựa hoàn toàn trên dữ liệu (*Data-driven*).



Hình 4.18: Cửa sổ phân tích

Kết luận

Dự án này đã đề xuất và xây dựng thành công hệ thống **G-SQM** (Geography-Specific Signal Quality Monitoring), một hệ thống giám sát tự động chất lượng vùng phủ tín hiệu chuyên biệt tới từng phân vùng địa lý. Hệ thống đã khai thác tối đa nguồn dữ liệu đo kiểm an danh MDT (Minimization of Drive Tests) từ thiết bị người dùng để thay thế phương pháp đo kiểm truyền thống (lái xe đi đo sóng thực địa). Module cảnh báo sớm tích hợp trong hệ thống có khả năng nhận diện các điểm "lỗ sóng" theo không gian và đưa ra dự báo biến động rủi ro trong 24 giờ tới dựa trên chuỗi thời gian về mật độ người dùng và cường độ sóng. Dashboard trực quan hóa dữ liệu không gian được xây dựng thành công bằng Streamlit và Kepler.gl với nhiều chức năng hỗ trợ kỹ sư đối chiếu trực quan, thống kê và chủ động đưa ra các quyết định tối ưu hạ tầng mạng lưới. Ngoài ra, hệ thống của chúng tôi sử dụng mô hình học máy Prophet triển khai phân tán để dự báo chuỗi thời gian, qua thực nghiệm chứng minh thuật toán bám sát tốt các chu kỳ biến động mạng lưới, đạt mức sai số MAE lý tưởng chỉ 5.14 dBm đối với chỉ số RSRP, tạo cơ sở vững chắc cho việc thay thế con người trong công tác cảnh báo tự động.

Điểm đột phá và đóng góp cốt lõi của G-SQM nằm ở phương pháp giám sát theo phân vùng lưới không gian lục giác H3 (Spatial Hashing) thay vì lấy trung bình toàn trạm phát, giúp khắc phục triệt để hiện tượng che lấp các vùng lỗ sóng cục bộ. Việc xây dựng thành công luồng dữ liệu phân tích tự động (End-to-End Pipeline) từ khâu thu thập, kiểm định chất lượng, nội suy H3 đến mô hình hóa dữ liệu (Star Schema) đã giúp tự động hóa hơn 80% các bước vận hành, giảm thiểu triệt để các thao tác trích xuất và tổng hợp dữ liệu thủ công của kỹ sư.

Bên cạnh những giá trị và đóng góp ấy, hệ thống vẫn còn những khía cạnh có thể tiếp tục nghiên cứu và phát triển trong tương lai. Đầu tiên, có thể nâng cấp kiến trúc xử lý từ lô (Batch Processing) sang luồng dữ liệu thời gian thực (Real-time Streaming) nhằm tối ưu hóa và giảm thiểu độ trễ cảnh báo. Tiếp đến, hệ thống có thể hướng tới việc tích hợp với Mạng lưới tự tổ chức (SON - Self-Organizing Networks), xây dựng các

module tự động đề xuất phương án san tải (điều chỉnh Tilt/Tx Power) ngay khi phát hiện các trạm phát (Cell) có nguy cơ quá tải cục bộ hoặc suy hao RSRP. Cuối cùng, việc mở rộng nền tảng bằng cách tích hợp hệ thống Backend (API Gateway) và Front-end chuyên nghiệp sẽ tạo cơ hội cung cấp dịch vụ trực tiếp cho người dùng cuối (End-user) thay vì chỉ giới hạn phục vụ cho các kỹ sư tối ưu vô tuyến như hiện tại.

Tài liệu tham khảo

- [1] 3GPP, “3GPP TS 37.320: Radio measurement collection for Minimization of Drive Tests (MDT),” 3rd Generation Partnership Project (3GPP), Technical Specification, 2023.
- [2] Apache Software Foundation, “Apache airflow,” <https://airflow.apache.org/>, 2024.
- [3] M. Armbrust, T. Das, L. Sun, B. Yavuz, S. Zhu, M. Murthy, J. Torres, H. van Kins, A. Finkelstein *et al.*, “Delta lake: high-performance acid table storage over cloud object stores,” *Proceedings of the VLDB Endowment*, vol. 13, no. 12, pp. 3411–3424, 2020.
- [4] Snowflake Inc., “Streamlit: A faster way to build and share data apps,” <https://streamlit.io/>, 2024.
- [5] Superconductive, “Great expectations: Always know what to expect from your data,” <https://greatexpectations.io/>, 2024.
- [6] S. J. Taylor and B. Letham, “Forecasting at scale,” *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [7] Trino Software Foundation, “Trino: Fast distributed sql query engine for big data analytics,” <https://trino.io/>, 2024.
- [8] Uber Technologies, Inc., “Kepler.gl: Make an impact with your location data,” <https://kepler.gl/>, 2024.
- [9] ———, “H3: Uber’s hexagonal hierarchical spatial index,” <https://h3geo.org/>, 2018.
- [10] M. Zaharia, M. Chowdhury, M. J. Franklin, S. Shenker, and I. Stoica, “Spark: Cluster computing with working sets,” *HotCloud*, vol. 10, no. 10-10, p. 95, 2010.